

Nr.: 139/30.12.2016

Raport științific

de cercetare-dezvoltare în cadrul Cloudifier SRL

Nume proiect	Platforma de migrare automatizată în cloud a aplicațiilor și sistemelor informatice clasice cloudifier.net
Beneficiar	CLOUDIFIER SRL
Cod MySMIS	104349
Nr. înregistrare	P_38_543
Director Proiect	Andrei Ionut DAMIAN
Activitate conform planului de proiect	1. Activități de cercetare-dezvoltare (cercetare industrială și/sau dezvoltare experimentală) - 1.1 State-of-the-art
Echipa de cercetare-dezvoltare	Andrei Ionut DAMIAN Octavian BULIE
Livrabil	Raport State-of-the-Art / 74 pag

Contents

1	Abstract.....	3
2	Analiza contextului cercetarii	4
2.1	Acronime.....	4
2.2	Obiectivele proiectului	5
2.3	Contextul proiectului.....	6
2.4	Sumarul activitatii de cercetare si rezultatele.....	8
2.5	Alte remarci.....	10
3	Rezultatele cercetarii.....	11
3.1	Problematica concreta analizata	11
3.2	Ecosistemul Cloudifier.NET	15
4	Doua directii de abordare avansata a cercetarii	16
4.1	Tehnici bazate pe modele avansate Shallow Machine Learning.....	17
4.1.1	Paralelizarea masiva a modelelor superfiale de invatare	17
4.1.2	Framework-ul state-of-the-art XGBoost.....	21
4.1.3	Modele proprii testate in Eigen.....	30
4.2	Tehnici bazate pe Retele Neurale Adanci	61
4.2.1	Utilizarea CNN in segmentarea semantica	61
4.2.2	Utilizarea LSTM pentru sisteme expert de tip Bot	61
4.2.3	Framework-ul state-of-the-art TensorFlow.....	62
4.2.4	Framework-ul state-of-the-art Keras.....	63
5	Anexa – Rapoarte lunare.....	64
5.1	Raport stiintific lunar 1	64
5.2	Raport stiintific lunar 2	68
5.3	Raport stiintific lunar 3	71

1 Abstract

În prezentul document este descris rezultatul etapei de cercetare industrială aferentă Activității 1 de cercetare industrială și/sau dezvoltare experimentală, sub-activitatea “State-of-the-Art”. Cercetarea industrială realizată în această etapă a constat în revizuirea stadiului actual al tehnicii/tehnologiilor atât în domeniul Cloud Computing / virtual desktop dar mai ales în domeniul recunoașterii și segmentării semantice a imaginilor prin algoritmi avansați de inteligență artificială, domeniu de cercetare ce a luat o deosebită amploare în ultimile 12 luni.

Scopul analizei, recunoașterii, segmentării semantice și a construcției unei hărți a imaginilor este de incorporare a acestor tehnologii avansate de inteligență artificială (Machine Learning) în motorul de migrare automatizată a aplicațiilor în mediul cloud. Intuitiv acest mecanism funcționează similar unui actor/observator uman care analizează o imagine după care reproduce într-un alt mediu din memorie elementele principale ale imaginii respective împreună cu poziția, forma și funcționalitatea lor în contextul analizat inițial.

2 Analiza contextului cercetarii

2.1 Acronime

Machine Learning = domeniu de cercetare-dezvoltare din cadrul Inteligentei Artificiale, aflat la fundamentul acesteia, prin care un sistem computerizat este capabil sa invete automatizat din propriile greseli cu sau fara supervizare sau orice forma de factor uman

Desktop computing = mod de lucru in care aplicatiile utilizate sunt rulate exclusiv pe o statie de lucru sau laptop fara a exista acces la o baza de date centralizata sau la sisteme online

Web- based computing = mod de lucru in care aplicatiile sunt rulate in cadrul unui server de web iar utilizatorii acceseaza functionalitatile respective prin intermediul browser-elor de internet

Legacy = Aplicatie sau modul dezvoltat in tehnologii inechite si/sau perimate care ruleaza in mediu de tip desktop computing

Client-Server = mod de lucru cu masive de date prin care acestea sunt centralizate pe un server de baze de date relationale

Segmentare semantica = analiza unei multimi, imagini, etc si identificarea elementelor componente ale acesteia

Cloud computing = tehnologie si mediu de rulare a sistemelor informatice prin care toate datele si functionalitatile aplicatiilor se acceseaza prin intermediul internetului si a aplicatiilor de tip web-based

Bot = aplicatie care simuleaza un interlocutor cu care utilizatorul comunica in limbaj natural (roBot) pentru rezolvarea unui set de probleme analizate cu ajutorul algoritmilor de tip Machine Learning

Python = limbaj de nivel inalt construit in special pentru mediul stiintific ce include capabilitati avansate pentru dezvoltare atat la nivel de experimentare cat si la nivel de productie

2.2 Obiectivele proiectului

In conformitate cu Cererea de finantare aferenta contractului de finantare nr 98/09.09.2016 obiectivul proiectului „PLATFORMA DE MIGRARE AUTOMATIZATA IN CLOUD A APLICATIILOR SI SISTEMELOR INFORMATICE CLASICE- Cloudifier.NET” este cercetarea, dezvoltarea si punerea in functiune in mediul comercial a produsului platforma inovativ Cloudifier.NET, ce se adreseaza domeniului tehnologiilor informatiei si comunicatiilor. In cadrul acestui obiectiv mentionam si intentia de diseminare publica partiala a rezultatelor proiectului sub licenta European Public License.

Obiectivul proiectului “PLATFORMA DE MIGRARE AUTOMATIZATA IN CLOUD A APLICATIILOR SI SISTEMELOR INFORMATICE CLASICE - Cloudifier.NET” raspunde uneia dintre prioritatile stabilite de Comisia Europeană prin Agenda Digitala 2020 si anume stimularea si facilitarea comerțului electronic la nivelul tarilor membre. Acest proiect va contribui major la sporirea utilizarii, calitatii si a accesului la tehnologia informatiei si comunicatiilor atat la nivelul local al Romaniei cat si la nivelul comunitatii de viitori potentiali utilizatori din intreaga Uniune Europeana iar implementarea cu succes a platformei va duce la sporirea contributiei sectorului TIC pentru competitivitatea economica a Romaniei. De asemenea, proiectul are ca obiectiv integrarea federalizarii cu conceptul de virtual desktop online, oferind astfel utilizatorului posibilitatea de a integra toate aplicatiile pe care le utilizeaza in mediul online – aplicatii de tip Cloud– intr-un singur spatiu virtual, in care sa dispuna de servicii de securizare si confidentialitate avansata a informatiilor.

La finalizarea implementarii produsul final va functiona ca o platforma de tip desktop online, bazata pe tehnologii de tip Cloud Computing, cu functionalitati multi-scop, care va

permite sustinerea proiectelor inovative din domeniul tehnologiei informatiilor si comunicatiilor si va facilita dezvoltarea sustenabila a acestora.

2.3 Contextul proiectului

Produsul Cloudifier.NET revendica prin unicitatea conceptului sau o serie de functionalitati total inovative, ce nu se regasesc la produsele comerciale deja existente in piata. In procesul de analiza preliminar a stadiului actual al tehnologiei (state-of-the-art), s-au luat in considerare o serie de produse comerciale relativ similare, pentru a se face o paralela intre acestea si Cloudifier.NET si a se determina detaliile avansului tehnologic dincolo de stadiul actual al tehnologiei (advances beyond state-of-the-art).

Implementarea proiectului „Platforma de migrare automatizata in Cloud a aplicatiilor si sistemelor informatice clasice- Cloudifier.NET” va permite:

- Sustinerea proiectelor inovative din domeniul tehnologiei informatiilor si comunicatiilor;
- Va facilita dezvoltarea sustenabila a acestora, prin oferirea accesului la o platforma de tip comunitate, in care sa poata gasi si regasi aplicatii si sisteme la cerere, utilizand astfel exclusiv structura de costuri de tip OPEX, fata de structurile clasice de tip CAPEX;
- Sprijinirea companiilor mari prin servicii “cost-effective” pentru migrarea de la aplicatii legacy- (aplicatii dezvoltate prin metode clasice de programare si implementare de tip desktop sau client-server, ce utilizeaza resurse bazate pe cheltuieli de capital, cum ar fi echipamente de calcul locale, licente locale, s.a.m.d - spre deosebire de modelul de aplicatii bazat pe tehnologia Cloud Computing care utilizeaza resurse la cerere scalabile, elastice si bazate aproape exclusiv pe modelul de cheltuieli operationale OPEX)" - la aplicatii in Cloud;
- Sprijinirea atat a mediului IMM, cat si a utilizatorilor privati, in vederea accesului la un mediu de tip spatiu virtual, personal de lucru online, in continua dezvoltare.

Unificarea avansului tehnologic adus de subplatforma avansata de translatare bazata de Machine Learning a aplicatiilor clasice in medii de tip Cloud cu avansul tehnologic propus de subplatforma de federalizare, brokeraj de date si spatiu virtual de lucru (virtual desktop), face ca platforma sa ofere o arie de inovare deosebit de generoasa, acoperind mai multe nevoi orizontale in domeniul tehnologiilor informatiilor si comunicatiilor, ce au impact asupra unor arii multiple tehnologice si variate industrii.

Cele doua subsisteme principale ale platformei Cloudfier sunt:

- A. subsistemul bazat pe Machine Learning de translatare inteligenta automatizata a aplicatiilor clasice desktop in aplicatii online in mediu de tip Cloud computing cu accent pe trecerea de la modele de sisteme informatice bazate pe CAPEX la modele de sisteme informatice bazate pe OPEX;
- B. subsistemul de federalizare a aplicatiilor de tip Cloud Computing provenite din surse multiple in vederea realizarii unei platforme de tip spatiu de lucru personal virtual online (online personal virtual desktop).

In concluzie directiile principale de utilitate ale platformei propuse sunt axate pe trei mari categorii distribuite in doua zone de inovatie dupa cum urmeaza:

- 1. Inovare in domeniu federalizarii platformelor, migrarii datelor si spatiilor personale virtuale:
 - 1.1. broker de servicii de Cloud pe care se inregistreaza furnizorii de servicii noi si inovative de Cloud;
 - 1.2. agregator si federalizator de servicii de Cloud prestandardizate
- 2. Inovare in domeniul migrarii aplicatiilor construite pe principiile clasice ale sistemelor informatice catre noile paradigme tehnologice definite de Cloud Computing:
 - 2.1. sistem inteligent bazat pe tehnici avansate de Machine Learning destinat traducerii aplicatiilor clasice desktop sau aplicatiilor client-server in aplicatii de tip Cloud Computing;
 - 2.2. provizionarea automatizata a aplicatiilor translatate in mediul platformei inovative

2.4 Sumarul activitatii de cercetare si rezultatele

Activitatea de cercetare a stadiului actual al tehnologiei s-a axat atat pe o serie de proiecte depuse in cadrul apelurilor de proiecte de cercetare beyond-state-of-the-art din cadrul Horizon 2020 dar mai ales pe lucrari publicate in cele mai renumite jurnale stiintifice cum ar fi:

- ✓ Journal of Machine Learning Research, www.jmlr.org (ISSN 1533-7928)
- ✓ International Journal of Neural Systems, ISSN:0129-0657
- ✓ IEEE Transactions on Pattern Analysis and Machine Intelligence, ISSN:0162-8828
- ✓ IEEE Transactions on Neural Networks and Learning Systems, ISSN:2162-237X
- ✓ Machine Learning, ISSN:0885-612
- ✓ International Journal of Intelligent Systems, ISSN:0884-8173
- ✓ Expert Systems with Applications, ISSN:0957-4174

De mentionat este faptul ca au fost analizate in mod particular lucrari ale celor mai cunoscuti cercetatori din domeniul inteligentei artificiale ca:

- ✓ Yoshua Bengio: <http://www.iro.umontreal.ca/~ben...>
- ✓ Geoffrey Hinton: <http://www.cs.toronto.edu/~hinton/>
- ✓ Alex Smola: <http://alex.smola.org/>
- ✓ Andrew Ng: <http://ai.stanford.edu/~ang/>
- ✓ Alex Krizhevsky: <http://www.cs.toronto.edu/~kriz/>
- ✓ Ilya Sutskever: <http://www.cs.toronto.edu/~ilya/>
- ✓ Andrej Karpathy: <http://cs.stanford.edu/people/karpathy/>
- ✓ Francois Chollet: <https://blog.keras.io/author/francois-chollet.html>
- ✓ Chris Meek: <http://research.microsoft.com/en...>
- ✓ Hugo Larochelle: http://www.dmi.usherb.ca/~larocheh/index_en.html
- ✓ Ian Goodfellow: https://en.wikipedia.org/wiki/Ian_Goodfellow
- ✓ Aaron Courville: <https://aaroncourville.wordpress.com/>
- ✓ Leo Breiman: <http://www.stat.berkeley.edu/~br...>
- ✓ Andrew McCallum: <http://www.cs.umass.edu/~mccallum/>
- ✓ Chris Meek: <http://research.microsoft.com/en...>
- ✓ Trevor Darrell: <https://people.eecs.berkeley.edu/~trevor/>

✓ Jonathan Long: <http://people.eecs.berkeley.edu/~jonlong/>

Din lucrarile analizate au fost extrase si analizate elemente cum ar fi:

1. Modelele de reconstructie arhitecturala si regenerare cod sursa
 - 1.1. Modele si metode de analiza a segmentarii ecranelor din cadrul aplicatiilor legacy bazate pe algoritmi clasici interactivi si modele de Machine Learning fara retele neurale adanci
 - 1.2. Modele si metode de segmentare semantica cu ajutorul retelor neurale adanci convolutionale a componentelor din cadrul ecranelor aplicatiilor legacy
 2. Modelele de migrare aplicatie
 - 2.1. Utilizarea retelor neurale recurente si in particular a LSTM (Long Short Term Memory) pentru realizarea de sisteme expert de tip bot care sa fie capabile de a asista utilizatorul in procesul de dezasamblare in subcomponente a aplicatiilor legacy si reasamblarea automatizata a acestora in medii de tip Cloud computing
- Deasemenea in vederea atingerii tuturor elementelor de analiza propuse au fost analizate tehnologii si abordari pentru probleme de inginerie si dezvoltare experimentală cu complexitate stiintifica mai redusa cum ar fi:
3. Modelele de analiza ale tehnologiei de tip baza de date utilizata in aplicatia legacy ce urmeaza a fi migrata
 - 3.1. Baze de date flat-file
 - 3.2. Baze de date relationale nebazate pe tehnologii client-server
 4. Modelele de analiza ale entitatilor de date
 - 4.1. Analiza bazata pe parcurgerea si recunoasterea grafurilor
 5. Modelele de analiza ale relationarii intre entitatile de date
 - 5.1. Analiza bazata pe parcurgerea si recunoasterea grafurilor
 6. Modelele de recunoastere a tehnologiei componentelor/modulelor sistemului
 - 6.1. Analiza bazata pe citirea componentelor sistemului de operare gazda
 7. Modelele de recunoasterele ale layere-lor de comunicare/API/etc.
 - 7.1. Analiza bazata pe citirea componentelor sistemului de operare gazda

2.5 Alte remarci

Directorul de proiect intentioneaza ca in baza cercetarii realizate in primul trimestru de implementare a proiectului “Platforma de migrare automatizată în cloud a aplicațiilor și sistemelor informatice clasice Cloudifier.net”, MySMIS: 104349, nr.: P_38_543, sa pregateasca si sa publice o lucrare stiintifica intr-o publicatie stiintifica cu recunoastere internationala.

3 Rezultatele cercetării

3.1 Problematika concreta analizata

Scopul analizei stadiului actual al tehnologiei este acela de a determina metodele cele mai moderne/actuale de realizare a predictiilor/inferentelor in imagistica – in particular in cazul proiectului CLOUDIFIER referindu-ne la analiza imaginilor captate in timp real in timpul functionarii aplicatiilor si implicit analiza automatizata cu ajutorul recunoasterii avansate de forme/imagini a aplicatiilor “legacy” in vederea translatarii acestora automatizate.

In decursul lunii octombrie 2016 au fost analizate cele mai recente si avansate lucrari de cercetare fundamentala si industriala provenite de la cele mai prestigioase institute si universitati printre care enumeram:

- ✓ Caltech – California Institute for Technology
- ✓ MIT – Massachusetts Institute for Technology
- ✓ Stanford
- ✓ University of Toronto
- ✓ Harvard
- ✓ University of Washington

Principalele zone analizate au fost:

- ✓ Metodele de tip Deep Learning bazate pe Retele Neuronale Convolutionale – Deep Convolutional Neural Networks
- ✓ Metode de tip shallow learning pentru invatarea supervizata a structurilor si a elementelor de imagistica utilizand modele de invatare in timp real (online learning)
- ✓ Cele mai moderne abordari in Deep Learning – Tensor Flow
- ✓ Cele mai moderne abordari in shallow learning – Extreme Boosted Decision Trees / Random Forests - XGBoost

În decursul lunii noiembrie 2016 au fost analizate cele mai recente și avansate lucrări de cercetare fundamentală în vederea determinării unui set de algoritmi de Machine Learning ideali pentru identificarea primitivelor de interfață grafică (butoane, câmpuri, ferestre, texte statice, etc) și a poziției acestora în cadrul ecranelor interfețelor grafice

- ✓ Determinarea unui algoritm de tip Machine Learning pentru generarea AUTOMATA de interfețe grafice și cod sursă aferente pe baza schițelor făcute manual pe suport de hârtie, tablă, etc
- ✓ Analiza TensorFlow
- ✓ Analiza XGBoost
- ✓ Analiza metode și propuneri pentru biblioteci interne
- ✓ Analiza și testarea experimentală a mediilor de procesare numerică masiv paralelă cu ajutorul GPU (tehnologiile bazate pe nuclee de calcul masiv paralel CUDA)

În decursul lunii decembrie 2016 a fost continuat procesul de analiză a stadiului curent al tehnologiei în domeniul sistemelor de tip Machine Learning cu accent pe zona de Deep Learning și în particular a sistemelor de analiză și recunoaștere bazată pe inteligență artificială a imaginilor. În decursul acestei luni analiza stadiului curent al cercetării a fost axată în principal pe lucrarea științifică publicată recent de J. Long et al “Fully Convolutional Networks for Semantic Segmentation”, lucrare considerată actualmente state-of-the-art în ceea ce privește metodele de recunoaștere și segmentare a componentelor în cadrul imaginilor. Pentru referință prezentăm anexat un scurt rezumat în limba engleză a lucrării de referință.

Principalele puncte pe care le urmărim în cercetare sunt următoarele:

1. Determinarea metodelor optime bazate pe Deep Learning pentru recunoașterea și segmentarea (identificarea locației spațiale) a elementelor de interfață grafică pe care Cloudifier.NET va trebui să le translateze automatizat din aplicațiile legacy în aplicațiile din mediul cloud computing.
2. Aplicarea de metode simple bazate pe algoritmi de machine learning superficiali (regresie logistică, arbori de decizie, clasificare naivă bazată pe teorema lui Bayes, clusterizare cu analiză a distanțelor euclidiene) precum și metode de segmentare

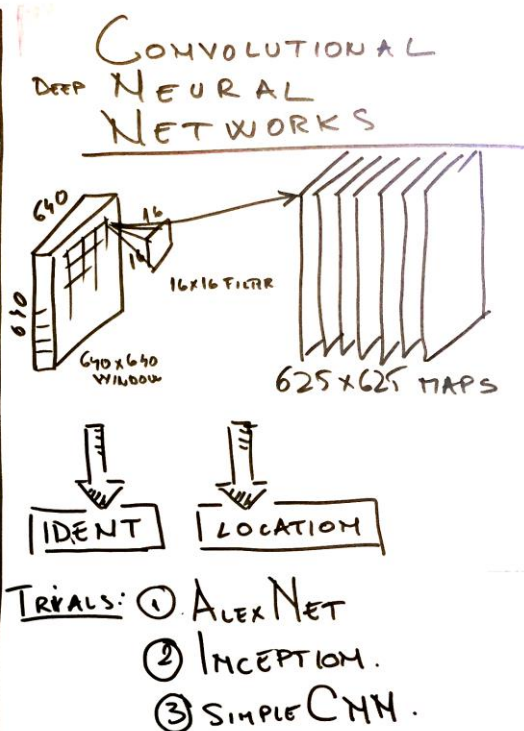
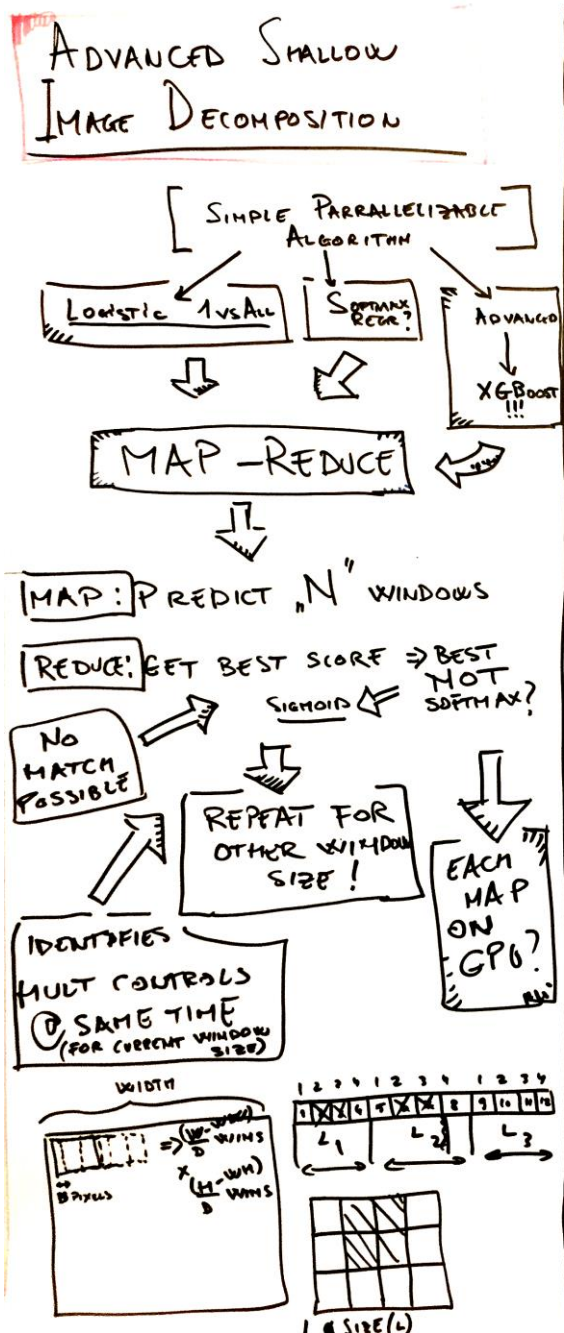
iterativa a imaginilor analizate cum ar fi metoda ferestrelor deplasate continuu (“ferestre alunecatoare” sau sliding-windows algorithm)

În Imaginea nr. 1 (“Schita de principiu a abordării stadiului actual al tehnologiei și avansurile aferente”) este prezentată abordarea celor două metode care vor fi proiectate în paralel în procesul de proiectare a modelelor arhitecturale ale etapei 1.2 din activitățile proiectului și ulterior experimentate în cadrul procesului de dezvoltare experimentală. Detaliile acestei abordări vor fi prezentate în secțiunea “3.3 Două direcții de abordare avansată a cercetării”

Imaginea 1 "Schita de principiu a abordarii stadiului actual al tehnologiei si avansurile aferente"

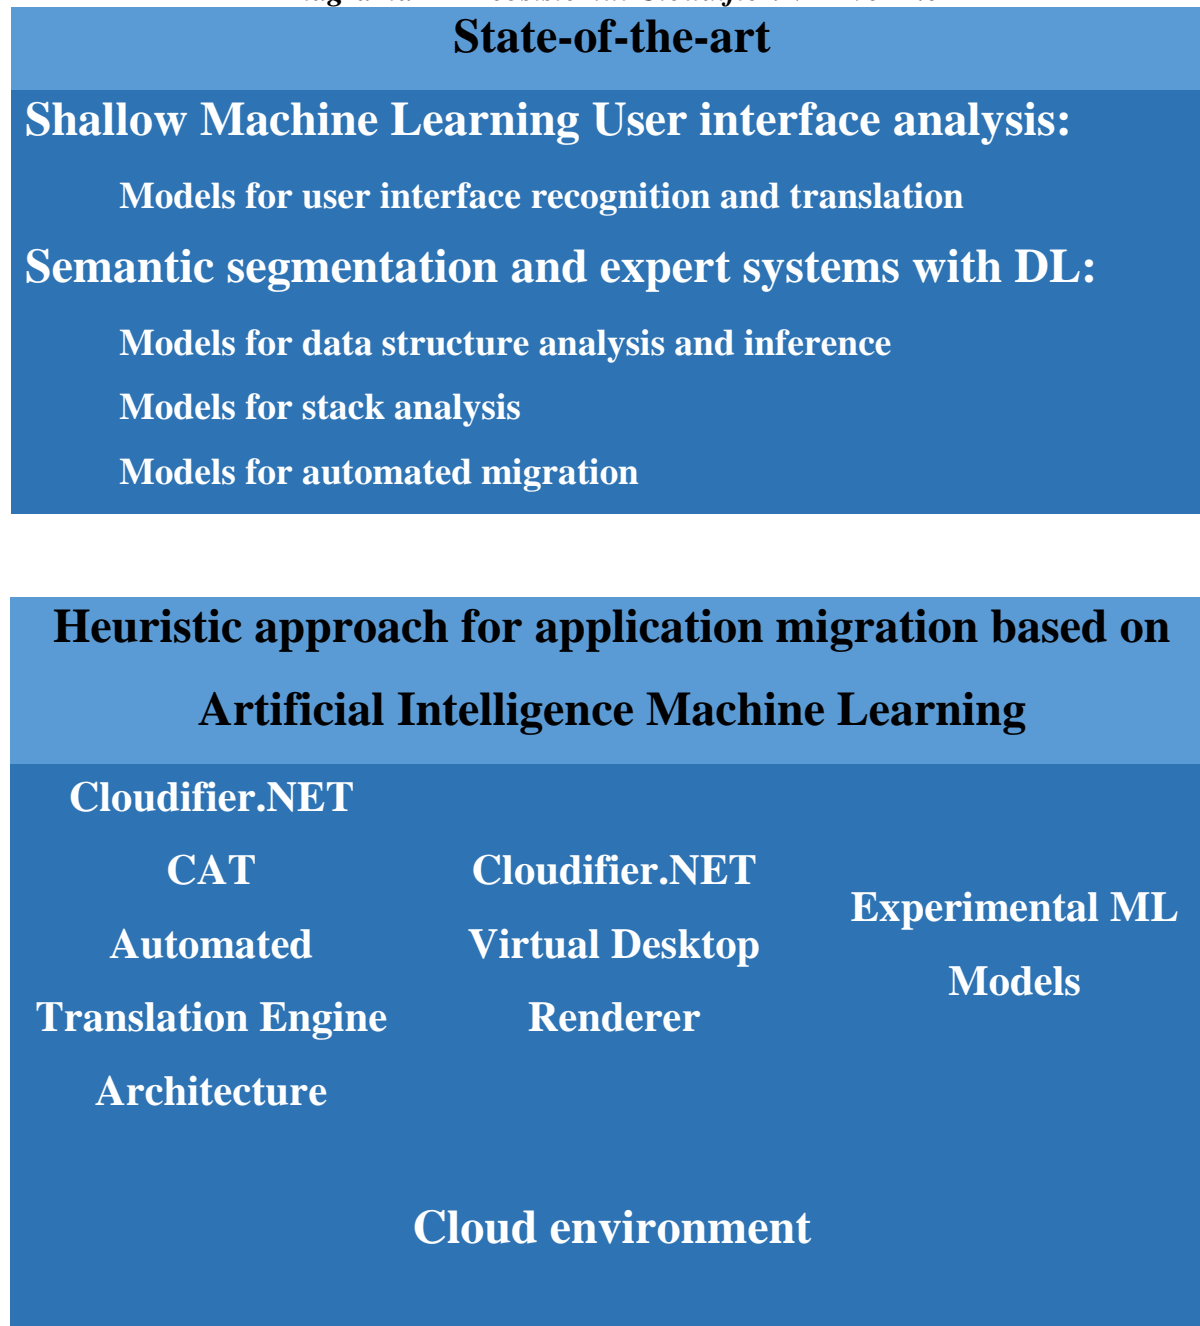
KEYS : XGBOOST,
ALEXNET, INCEPTION,
SUDOING / LINEAR.

CLOUDIFIER.NET
STATE OF THE ART & BEYOND



3.2 Ecosistemul Cloudifier.NET

Diagrama 2 – Ecosistemul Cloudifier.NET ver 1.0



Ecosistemul Cloudifier.NET descris în Diagrama 2 cuprinde toate elementele descrise în documentația Cererii de Finanțare și proiectului tehnic aferente proiectului “Platforma de migrare automatizată în cloud a aplicațiilor și sistemelor informatice clasice cloudifier.net” al

CLOUDIFIER SRL cu codul MySMIS 2014 nr 104349 si numarul de inregistrare online P_38_543. La elementele initiale au fost adaugate si vor fi detaliate pe parcursul activitatilor de cercetare-dezvoltare elementele principale bazate pe tehnologii de Machine Learning.

4 Doua directii de abordare avansata a cercetarii

Conform diagramei descrise anterior si a imaginii 1 ce descrie schita de principiu a abordarii proiectului, in urma analizei stadiului actual al tehnologiei au fost determinate doua directii principale in care se vor desfasura activitati de modelare arhitecturala si dezvoltare experimentala in urmatoarea perioada:

1. Modele avansate de recunoastere si decompoziei a cadrelor (imaginilor) din aplicatiile legacy prin utilizarea de algoritmi paralelizabili de predictie bazata pe tehnici de machine learning fara retele neurale adanci
2. Modele de segmentare semantica precum si proiectare de sisteme automatizate expert de tip "Bot" cu ajutorul retelelor neurale adanci convolutionale si recurente (LSTM)

4.1 Tehnici bazate pe modele avansate Shallow Machine Learning

4.1.1 Paralelizarea masiva a modelelor superfiale de invatare

Prin utilizarea tehnicilor de ultima generatie si in particular a tehnologiei state-of-the-art PASCAL creeata si lansata in 2016 de NVidia se vor utiliza structuri de calcul masiv paralel cu peste 1500 de nuclee de calcul numeric paralelizat.

Aceasta abordare va permite aplicarea de algoritmi de invatare a modelelor superfiale Machine Learning pe structuri de date cu complexitate si dimensionalitate foarte mare – spre exemplu imagini cu adancime de culoare pe 32 de biti (4 octeti) si rezolutii reale de peste W:2000 H:2000. Pentru cazul particular al proiectului Cloudifier.NET este necesara analiza in timp real a imaginilor cu rezolutii inalte peste 1080x786x4 ceea ce genereaza un minim de 829,000 de dimensiuni (variabile predictor) . Astfel se vor putea aplica algoritmi de tip regresie logistica softmax antrenata prin mini-calupuri informationale pe structura de calcul masiv paralel.

Detaliile modului de aplicare a algoritmilor vor fi definite in etapa dezvoltarii subactivitatii 1.2 de proiectare a modelelor arhitecturale

Print utilizarea celor mai recente cercetarii in domeniul Machine Learning pentru ansamble de modele se urmareste testarea experimentală a potentialei utilizari de modele simple si eficiente pentru toate componentele de inteligenta artificiala ale proiectului Cloudifier.NET. Aceste componente vor fi asociate cu algoritmi clasici de tip “Sliding Windows” – utilizati actualmente de camerele de luat vederi de ultima generatie - care vor genera mecanic segmentele ce urmeaza sa fie analizate de algoritmii de tip Machine Learning.

In cele ce urmeaza este prezentat un test realizat cu ajutorul tehnologiei CUDA a NVidia pentru calcul masiv paralel utilizand limbajul de nivel inalt Python

```
1 # Exercise 1 from http://webapp.dam.brown.edu/wiki/SciComp/CudaExercises  
2  
3 # Transposition of a matrix
```

```
4 # by Hendrik Riedmann <riedmann@dam.brown.edu>
5
6 from future import division, print function
7
8 import pycuda.driver as cuda
9 import pycuda.gpuarray as gpuarray
10 import pycuda.autotinit
11 from pycuda.compiler import SourceModule
12
13 import numpy
14 import numpy.linalg as la
15
16 from pycuda.tools import context_dependent_memoize
17
18 block_size = 16
19
20 @context_dependent_memoize
21 def _get_transpose_kernel():
22     mod = SourceModule("""
23     #define BLOCK_SIZE %(block_size)d
24     #define A BLOCK STRIDE (BLOCK_SIZE * a width)
25     #define A T BLOCK STRIDE (BLOCK_SIZE * a height)
26
27     __global__ void transpose(float *A_t, float *A, int a_width, int a_height)
28     {
29         // Base indices in A and A t
30         int base_idx a = blockIdx.x * BLOCK_SIZE +
31         blockIdx.y * A_BLOCK_STRIDE;
32         int base_idx_a_t = blockIdx.y * BLOCK_SIZE +
33         blockIdx.x * A_T_BLOCK_STRIDE;
34
35         // Global indices in A and A t
36         int glob_idx_a = base_idx a + threadIdx.x + a_width * threadIdx.y;
37         int glob_idx_a_t = base_idx_a_t + threadIdx.x + a_height * threadIdx.y;
38
39         __shared__ float A_shared[BLOCK_SIZE][BLOCK_SIZE+1];
40
41         // Store transposed submatrix to shared memory
42         A_shared[threadIdx.y][threadIdx.x] = A[glob_idx_a];
43
44         __syncthreads();
45
46         // Write transposed submatrix to global memory
47         A t[glob_idx a t] = A_shared[threadIdx.x][threadIdx.y];
48     }
49     """) % {"block_size": block_size})
50
51 func = mod.get_function("transpose")
52 func.prepare("PPii")
53
54 from pytools import Record
55 class TransposeKernelInfo(Record): pass
56
57 return TransposeKernelInfo(func=func,
58                             block=(block_size, block_size, 1),
59                             block_size=block_size,
60                             granularity=block_size)
61
62
63
64 def _get_big_block_transpose_kernel():
65     mod = SourceModule("""
66     #define BLOCK_SIZE %(block_size)d
67     #define A BLOCK STRIDE (BLOCK_SIZE * a width)
68     #define A T BLOCK STRIDE (BLOCK_SIZE * a height)
69
70     __global__ void transpose(float *A, float *A_t, int a_width, int a_height)
71     {
72         // Base indices in A and A t
73         int base_idx a = 2 * blockIdx.x * BLOCK_SIZE +
74         2 * blockIdx.y * A_BLOCK_STRIDE;
```

```
75     int base_idx_a_t = 2 * blockIdx.y * BLOCK_SIZE +
76     2 * blockIdx.x * A_T_BLOCK_STRIDE;
77
78     // Global indices in A and A t
79     int glob_idx_a = base_idx_a + threadIdx.x + a_width * threadIdx.y;
80     int glob_idx_a_t = base_idx_a_t + threadIdx.x + a_height * threadIdx.y;
81
82     shared float A_shared[2 * BLOCK_SIZE][2 * BLOCK_SIZE + 1];
83
84     // Store transposed submatrix to shared memory
85     A_shared[threadIdx.y][threadIdx.x] = A[glob_idx_a];
86     A_shared[threadIdx.y][threadIdx.x + BLOCK_SIZE] =
87     A[glob_idx_a + A_BLOCK_STRIDE];
88     A_shared[threadIdx.y + BLOCK_SIZE][threadIdx.x] =
89     A[glob_idx_a + BLOCK_SIZE];
90     A_shared[threadIdx.y + BLOCK_SIZE][threadIdx.x + BLOCK_SIZE] =
91     A[glob_idx_a + BLOCK_SIZE + A_BLOCK_STRIDE];
92
93     __syncthreads();
94
95     // Write transposed submatrix to global memory
96     A_t[glob_idx_a_t] = A_shared[threadIdx.x][threadIdx.y];
97     A_t[glob_idx_a_t + A_T_BLOCK_STRIDE] =
98     A_shared[threadIdx.x + BLOCK_SIZE][threadIdx.y];
99     A_t[glob_idx_a_t + BLOCK_SIZE] =
100     A_shared[threadIdx.x][threadIdx.y + BLOCK_SIZE];
101     A_t[glob_idx_a_t + A_T_BLOCK_STRIDE + BLOCK_SIZE] =
102     A_shared[threadIdx.x + BLOCK_SIZE][threadIdx.y + BLOCK_SIZE];
103 }
104 """" { "block_size": block_size }
105
106 func = mod.get_function("transpose")
107 func.prepare("PPii")
108
109 from pytools import Record
110 class TransposeKernelInfo(Record): pass
111
112 return TransposeKernelInfo(func=func,
113                             block=(block_size, block_size, 1),
114                             block_size=block_size,
115                             granularity=2*block_size)
116
117
118
119
120 def _transpose(tgt, src):
121     krnl = _get_transpose_kernel()
122
123     w, h = src.shape
124     assert tgt.shape == (h, w)
125     assert w % krnl.granularity == 0
126     assert h % krnl.granularity == 0
127
128     krnl.func.prepared_call(
129         (w // krnl.granularity, h // krnl.granularity), krnl.block,
130         tgt.gpudata, src.gpudata, w, h)
131
132
133
134
135 def transpose(src):
136     w, h = src.shape
137
138     result = gpuarray.empty((h, w), dtype=src.dtype)
139     transpose(result, src)
140     return result
141
142
143
144
145
```

```
146 def check_transpose():
147     from pycuda.curandom import rand
148
149     for i in numpy.arange(10, 13, 0.125):
150         size = int((2**i) // 32) * 32
151         print(size)
152
153         source = rand((size, size), dtype=numpy.float32)
154
155         result = transpose(source)
156
157         err = source.get().T - result.get()
158         err_norm = la.norm(err)
159
160         source.gpudata.free()
161         result.gpudata.free()
162
163         assert err_norm == 0, (size, err_norm)
164
165
166
167
168 def run_benchmark():
169     from pycuda.curandom import rand
170
171     powers = numpy.arange(10, 13, 2**(-6))
172     sizes = [int(size) for size in numpy.unique(2**powers // 16 * 16)]
173     bandwidths = []
174     times = []
175
176     for size in sizes:
177
178         source = rand((size, size), dtype=numpy.float32)
179         target = gpuarray.empty((size, size), dtype=source.dtype)
180
181         start = pycuda.driver.Event()
182         stop = pycuda.driver.Event()
183
184         warmup = 2
185
186         for i in range(warmup):
187             _transpose(target, source)
188
189         count = 10
190
191         cuda.Context.synchronize()
192         start.record()
193
194         for i in range(count):
195             _transpose(target, source)
196
197         stop.record()
198         stop.synchronize()
199
200         elapsed_seconds = stop.time_since(start)*1e-3
201         mem_bw = source.nbytes / elapsed_seconds * 2 * count
202
203         bandwidths.append(mem_bw)
204         times.append(elapsed_seconds)
205
206     slow_sizes = [s for s, bw in zip(sizes, bandwidths) if bw < 40e9]
207     print("Sizes for which bandwidth was low:", slow_sizes)
208     print("Ditto, mod 64:", [s % 64 for s in slow_sizes])
209     from matplotlib.pyplot import semilogx, loglog, show, savefig, clf, xlabel, ylabel
210     xlabel('matrix size')
211     ylabel('bandwidth')
212     semilogx(sizes, bandwidths)
213     savefig("transpose-bw.png")
214     clf()
215     xlabel('matrix size')
216     ylabel('time')
```

```
217 loglog(sizes, times)
218 savefig("transpose-times.png")
219
220
221
222
223 #check_transpose()
224 run_benchmark()
```

4.1.2 Framework-ul state-of-the-art XGBoost

În vederea aplicării celor mai recente cercetări în domeniile vizate a fost selectat printre modelele state-of-the-art și framework-ul XGBoost dezvoltat în perioada 2015-2016, framework ce a fost popularizat în perioada desfășurată după depunerea aplicației inițiale a proiectului Cloudifier și actualmente este considerat state-of-the-art în domeniul modelelor de tip ansamblu de algoritmi de inteligență artificială destinați predicției.

În continuare prezentăm testele realizate pe această tehnologie pe parcursul desfășurării activităților 1.1 – Analiza State-of-the-Art

"""

Created on: 10/27/2016

Last Modified: 12/23/2016

@author: Andrei Ionut DAMIAN

"""

Tune learning_rate

from numpy import loadtxt

from xgboost import XGBClassifier

from sklearn.grid_search import GridSearchCV

from sklearn.cross_validation import StratifiedKFold

```
from sklearn.ensemble import RandomForestClassifier

from sklearn.ensemble import VotingClassifier

from sklearn.linear_model import LogisticRegression

from sklearn.svm import SVC

from sklearn.neighbors import KNeighborsClassifier

from sklearn.model_selection import GridSearchCV

from xgboost import XGBClassifier

from xgboost import XGBRegressor

import pandas as pd

import numpy as np

from sklearn.model_selection import train_test_split

from sklearn.metrics import accuracy_score

from sklearn.metrics import mean_absolute_error

from sklearn.metrics import make_scorer

from sklearn.preprocessing import StandardScaler

import sys

import re

import time

def copy_from_combined(train_ds, test_ds, combined_ds, columns, index_pos):

    for column in columns:

        train_ds.set_value(train_ds.index, column, combined_ds[:index_pos][column].values)

        test_ds.set_value(test_ds.index, column, combined_ds[index_pos:][column].values)

if __name__ == "__main__":

    Verbose = False
```

```
init_train_data = pd.read_csv('train.csv')

init_test_data = pd.read_csv('test.csv')


train_data = init_train_data.copy()

test_data = init_test_data.copy()


sex_values={'male':1,'female':0}

train_data['Sex']=train_data['Sex'].replace(sex_values)

test_data['Sex']=test_data['Sex'].replace(sex_values)


train_data.set_value(train_data.Embarked.isnull(), "Embarked", "C")

test_data.set_value(test_data.Fare.isnull(), 'Fare', 8.05) # the 60 year old guy


train_data.set_value(train_data.Cabin.isnull(), 'Cabin', 'U0')

test_data.set_value(test_data.Cabin.isnull(), 'Cabin', 'U0')


###

### feature engineering

### all features will begin with EF_ prefix

###

# create nr of names feature

train_names = train_data.Name.map(lambda x: len(re.split(' ', x)))

train_data.set_value(train_data.index, 'EF_Names', train_names)

del train_names
```

```
test_names = test_data.Name.map(lambda x: len(re.split(' ', x)))

test_data.set_value(test_data.index, 'EF_Names', test_names)

del test_names


#create title feature (later will be factorized/O.H.E.-ed)

prog = re.compile(' (.*?)\s\.')

title = train_data.Name.map(lambda x: prog.findall(x)[0])

title[title=='Mme'] = 'Mrs'

title[title.isin(['Ms', 'Mlle'])] = 'Miss'

title[title.isin(['Don', 'Jonkheer'])] = 'Sir'

title[title.isin(['Dona', 'Lady', 'the Countess'])] = 'Lady'

title[title.isin(['Capt', 'Col', 'Major', 'Dr', 'Officer', 'Rev'])] = 'Officer'

_ = train_data.set_value(train_data.index, 'EF_Title', title)

del title


title = test_data.Name.map(lambda x: prog.findall(x)[0])

title[title=='Mme'] = 'Mrs'

title[title.isin(['Ms', 'Mlle'])] = 'Miss'

title[title.isin(['Don', 'Jonkheer'])] = 'Sir'

title[title.isin(['Dona', 'Lady', 'the Countess'])] = 'Lady'

title[title.isin(['Capt', 'Col', 'Major', 'Dr', 'Officer', 'Rev'])] = 'Officer'

_ = test_data.set_value(test_data.index, 'EF_Title', title)

del title


##

## from now on we will combine both TRAIN and TEST in order to computer

## accurate averages/predictions for certain variables and engineered
```



```
## predictors that we will construct

##

combined = pd.concat([train_data, test_data], ignore_index=True)

## Generate "Deck" feature - factorization of Cabin 1st letter

deck = combined[~combined.Cabin.isnull()].Cabin.map( lambda x : re.compile("[a-zA-Z]+").search(x).group())

deck = pd.factorize(deck)[0]

combined.set_value(combined.index, 'EF_Deck', deck)

del deck

## Extract "Room" feature - the number contained in the cabin

## info. Standardize the result

checker = re.compile("[0-9]+")

def roomNum(x):

    nums = checker.search(x)

    if nums:

        return int(nums.group())+1

    else:

        return 1

rooms = combined.Cabin.map(roomNum)

_ = combined.set_value(combined.index, 'EF_Room', rooms)

combined['EF_Room'] = (combined.EF_Room-combined.EF_Room.min())/combined.EF_Room.max()

del checker, roomNum

## now compute Group size

combined['EF_Group_size'] = combined.Parch + combined.SibSp + 1

combined['EF_Group_type'] = pd.Series('M', index=combined.index)

combined.set_value(combined.EF_Group_size >4, 'EF_Group_type', 'L')

combined.set_value(combined.EF_Group_size==1, 'EF_Group_type', 'S')
```

```
##

# save work in train/test

saved_cols = ['EF_Deck', 'EF_Room', 'EF_Group_type', 'EF_Group_size',
              'EF_Names', 'EF_Title']

copy_from_combined(train_data, test_data, combined, saved_cols, 891 )

# done saving

# transform 'Embarked', 'Sex', 'EF_Title', 'EF_Group_type' in OH features

# normalize Fare

scaler = StandardScaler()

combined['EF_Fare']      =      pd.Series(scaler.fit_transform(combined.Fare.reshape(-
1,1)).reshape(-1),

                                         index=combined.index)

## now lets drop some of standard predictors that have been

## re-engineered

combined.drop(labels=['PassengerId', 'Name', 'Cabin', 'Survived', 'Ticket', 'Fare'],
              axis=1, inplace=True)

## now lets encode as planned

combined = pd.get_dummies(combined,

                           columns=['Embarked', 'Sex', 'EF_Title', 'EF_Group_type'])

# now FINALLY predict AGE

X_train_age = combined[~combined.Age.isnull()].drop('Age', axis=1)

y_train_age = combined[~combined.Age.isnull()].Age

xgb_regressor = XGBRegressor(max_depth=4)

regr_scoring = make_scorer(mean_absolute_error, greater_is_better=False)

regr_parameters = {'reg_alpha': np.linspace(0.1,1.0,5),
                  'reg_lambda': np.linspace(1.0,3.0,5)}
```

```
tmp_rgr = GridSearchCV(xgb_regressor,

                        param_grid = regr_parameters,

                        scoring = regr_scoring,

                        n_jobs=6)

tmp_rgr.fit(X_train_age, y_train_age)

reg_xgb = tmp_rgr.best_estimator_

age_preds = reg_xgb.predict(combined[combined.Age.isnull()].drop('Age', axis=1))

combined.set_value(combined.Age.isnull(), 'Age', age_preds)

combined['EF_NorAge']      =      pd.Series(scaler.fit_transform(combined.Age.reshape(-
1,1)).reshape(-1),

                                             index=combined.index)

combined['EF_NorNames']    =    pd.Series(scaler.fit_transform(combined.EF_Names.reshape(-
1,1)).reshape(-1),

                                             index=combined.index)

combined['EF_Group_size']                                     =
pd.Series(scaler.fit_transform(combined.EF_Group_size.reshape(-1,1)).reshape(-1),

                                             index=combined.index)

# now save processed engineered features

saved_cols = ['EF_NorAge', 'EF_NorNames', 'EF_Group_size', 'EF_Fare']

copy_from_combined(train_data, test_data, combined, saved_cols, 891 )

# done

# clean features that have been transformed

train_data.drop(labels=['PassengerId', 'Name', 'EF_Names', 'Cabin', 'Ticket', 'Age',
'Fare'],

                 axis=1, inplace=True)
```

```
test_data.drop(labels=                ['Name', 'EF_Names', 'Cabin', 'Ticket', 'Age',  
'Fare'],
```

```
axis=1, inplace=True)
```

```
train_data = pd.get_dummies(train_data, columns=['Embarked', 'Pclass', 'EF_Title',  
'EF_Group_type'])
```

```
test_data = pd.get_dummies(test_data, columns=['Embarked', 'Pclass', 'EF_Title',  
'EF_Group_type'])
```

```
test_data['EF_Title_Sir'] = pd.Series(0, index=test_data.index) # missing in test  
dataset
```

```
X = train_data.drop(['Survived'], axis=1)
```

```
Y = train_data.Survived
```

```
# grid search
```

```
model = XGBClassifier()
```

```
learning_rate = [0.01, 0.1, 0.2, 0.3]
```

```
reg_lambda = [ 2.0, 3.0, 4.0, 5.0]
```

```
reg_alpha =[2.0, 3.0, 4.0, 5.0]
```

```
n_estimators = [100, 400]
```

```
max_depth = [4, 6, 8]
```

```
param_grid = dict(max_depth = max_depth,  
                   n_estimators = n_estimators,  
                   learning_rate = learning_rate,  
                   reg_alpha = reg_alpha,  
                   reg_lambda = reg_lambda)
```

```
kfold = StratifiedKFold(Y, n_folds=10, shuffle=True)

scoring = make_scorer(accuracy_score, greater_is_better=True)

grid_search = GridSearchCV(model,

                             param_grid,

                             scoring= scoring,

                             n_jobs=-1,

                             cv=kfold)

result = grid_search.fit(X, Y)

final_clf = result.best_estimator_

# summarize results

means, stdevs = [], []

for params, mean_score, scores in result.grid_scores_:

    stdev = scores.std()

    means.append(mean_score)

    stdevs.append(stdev)

    print("%f (%f) with: %r" % (mean_score, stdev, params))

print("Best: %f using %s" % (result.best_score_, result.best_params_))

SAVE = True

if SAVE:

    PassengerId = test_data.PassengerId

    test_data.drop("PassengerId", axis = 1, inplace = True)

    test_data = test_data[X.columns]

    y_f_preds = final_clf.predict(test_data)

    save_data = pd.DataFrame(columns = ['PassengerId', 'Survived'])

    save_data.PassengerId = PassengerId

    save_data.Survived = pd.Series(y_f_preds, index=save_data.index)

    file_name = str(time.time())+'_pxgb_predictions.csv'
```

```
save_data.to_csv(file_name, index=False)
```

4.1.3 Modele proprii testate in Eigen

O alta abordare in vederea determinarii celei mai eficiente si fiabile solutii pentru implementarea componentelor de Machine Learning din cadrul Cloudifier.NET este utilizarea bibliotecilor de nivel scazut scrise in C++, biblioteci ce formeaza actualmente state-of-the-art in aceasta zona si au fost analizate in cadrul etapei/subactivitatii 1.1 “Analiza state-of-the-art” a proiectului. In particular au fost analizate bibliotecile EIGNEN (http://eigen.tuxfamily.org/index.php?title=Main_Page sau [https://en.wikipedia.org/wiki/Eigen_\(C%2B%2B_library\)](https://en.wikipedia.org/wiki/Eigen_(C%2B%2B_library)))

In continuare prezentam testele realizate pe aceasta tehnologie pe parcursul desfasurarii activitatilor 1.1 – Analiza State-of-the-Art. Aceste teste reprezinta implementarea la nivelul cel mai jos al nucleului de calcul a algoritmului de Machine Learning bazat regresia logistica softmax.

```
//  
// EigenEngine - ML engine based on Eigen library  
//  
// Created: 11/01/2016  
// Last modified: 12/29/2016  
//  
// @Author: Andrei Ionut DAMIAN  
// @Contributor: Octavian BULIE  
  
#pragma once  
  
#include "stdafx.h"  
#include "stdio.h"  
#include <string>  
#include <iostream>  
#include <fstream>  
#include <vector>
```

```
#include <set>

#include <Eigen/Dense>
#include <Eigen/Core>
#include <Eigen/SVD>

#include <sys/stat.h>

#include <chrono>

#include <algorithm>
#include <random>

using namespace std;
using namespace std::chrono;

using Eigen::MatrixXd;
using Eigen::VectorXd;

using namespace Eigen;
using namespace std;

struct TrainCrossSplits
{
    MatrixXd X_train;
    MatrixXd X_cross;
    vector <string> Labels;
    VectorXd y_train;
    VectorXd y_cross;
};

class GenericEngine
{
private:
```

```
long LoadedDataNrFields;

long LoadedDataNrRows;

long TrainTestSplitPos;

std::default_random_engine random_engine;

protected:

    milliseconds start_time;

    milliseconds end_time;

    bool bBiasAdded; // variable that stores bias information for pre-loaded data

    string CLF_NAME;

    long NR_FEATS;

    long NR_CLASSES;

public:

    bool VERBOSE_ENGINE;

    MatrixXd *X_loaded;

    VectorXd *y_loaded;

    MatrixXd *X_train;

    VectorXd *y_train;

    MatrixXd *X_cross;

    VectorXd *y_cross;

    MatrixXd *LoadedData;

    vector <string> LoadedDataHeader;

    vector <string> LabelsVector;

    GenericEngine()

    {

        CLF_NAME = "Generic Engine";
```



```
// obtain a time-based seed:
unsigned seed = std::chrono::system_clock::now().time_since_epoch().count();
random_engine = default_random_engine(seed);

VERBOSE_ENGINE = true;

bBiasAdded = false;

X_train = NULL;
y_train = NULL;
X_loaded = NULL;
y_loaded = NULL;
X_cross = NULL;
y_cross = NULL;
LoadedData = NULL;
}

bool file_exists(const std::string& name);

void debug_info(string str_message)
{
    if (VERBOSE_ENGINE)
        printf("\n[DEBUG] %s", str_message.c_str());
}

void debug_info(string msg, MatrixXd mat)
{
    std::stringstream ss;
    ss << mat;
    string str_matrix = ss.str();
    string msgp = "\n[DEBUG] " + msg + "\n";
    printf(msgp.c_str());
    std::cout << str_matrix << std::endl;
}

void debug_info(MatrixXd mat)
```



```
}

MatrixXd ShuffleMatrixRows(MatrixXd DataMatrix);

int FindLabelId(vector <string> labels, string value);

void BeginTimer();
long EndTimer();

vector <string> ToLabels(VectorXd y);

TrainCrossSplits LoadCSV(const string& inputfile, const bool bShuffle = false, const
bool bAddBias = false);

};

class GenericLinearEngine : public GenericEngine
{
protected:

    long nr_batches; // how many batches have been processed (epochs, online trainings,
etc)

    VectorXd *SingleClassTheta;
    MatrixXd *Theta;
    VectorXd *J_values;

    void add_cost(double J);

private:

    void init();

public:
```

```
GenericLinearEngine()  
{  
    CLF_NAME = "VIRTUAL Generic Linear Engine";  
    init();  
}  
~GenericLinearEngine()  
{  
    debug_info("Deleting object [" + CLF_NAME + "]");  
  
    if (LoadedData != NULL)  
        delete LoadedData;  
    if (X_loaded != NULL)  
        delete X_loaded;  
    if (y_loaded != NULL)  
        delete y_loaded;  
    if (X_train != NULL)  
        delete X_train;  
    if (y_train != NULL)  
        delete y_train;  
    if (X_cross != NULL)  
        delete X_cross;  
    if (y_cross != NULL)  
        delete y_cross;  
    if (Theta != NULL)  
        delete Theta;  
    if (SingleClassTheta != NULL)  
        delete SingleClassTheta;  
    if (J_values != NULL)  
        delete J_values;  
}  
  
VectorXd PredictSingleClass(MatrixXd X);  
  
virtual MatrixXd Predict(MatrixXd X);  
  
vector <string> PredictLabels(MatrixXd X);
```

```
vector <string> PredictLabelsUsingYHat(MatrixXd y_hat);

string GetName();
MatrixXd& GetTheta();

float NRMSE(VectorXd y_hat, VectorXd y);
float RMSE(VectorXd y_hat, VectorXd y);
float CrossEvaluationSingleClass(bool bClass);
float TrainEvaluationSingleClass(bool bClass);

float CrossEvaluation(bool bClass);
float TrainEvaluation(bool bClass);
};

class NormalRegressor : public GenericLinearEngine
{
protected:

    int t;

public:
    NormalRegressor()
    {
        NR_FEATS = 0;
        NR_CLASSES = 0;
        CLF_NAME = "Batch Normal Regressor";
    }

    void Train(MatrixXd X, MatrixXd y);
    void Train();
};

class OnlineClassifier : public GenericLinearEngine
{
protected:
```

```
// temp variables

MatrixXd LastYHat;
MatrixXd LastGrad;
MatrixXd LastXObs;
MatrixXd LastYOHM;
MatrixXd LastYERR;

double LearningRate;

MatrixXd softmax(MatrixXd z);
double cross_entropy(MatrixXd yOHM, MatrixXd y_hat);

public:
    OnlineClassifier(int nr_features, int nr_classes, vector <string> &labels, double
alpha_learning_rate)
    {
        CLF_NAME = "Online Linear Classifier";
        NR_FEATS = nr_features;
        NR_CLASSES = nr_classes;
        LabelsVector = labels;
        LearningRate = alpha_learning_rate;

        Theta = new MatrixXd(NR_FEATS+1, NR_CLASSES); // add 1 row for biases

        Theta->fill(0);
    }

    void SimulateOnlineTrain();

    void OnlineTrain(MatrixXd xi, VectorXd yi);

    double CostFunction();

    MatrixXd Predict(MatrixXd X);
```

```
};

//
// BEGIN Generic Engine Class definitions - basic ancestor helper class
//

inline bool GenericEngine::file_exists(const std::string & name)
{
    if (FILE *file = fopen(name.c_str(), "r")) {
        fclose(file);
        return true;
    }
    else {
        return false;
    }
}

inline MatrixXd GenericEngine::ShuffleMatrixRows(MatrixXd DataMatrix)
{
    long size = DataMatrix.rows();
    PermutationMatrix<Dynamic, Dynamic> perm(size);
    perm.setIdentity();

    std::shuffle(perm.indices().data(),
                perm.indices().data() + perm.indices().size(),
                this->random_engine);

    MatrixXd A_perm = perm * DataMatrix; // permute rows
    return(A_perm);
}

inline int GenericEngine::FindLabelId(vector<string> labels, string value)
{

```

```
int pos = find(labels.begin(), labels.end(), value) - labels.begin();

if (pos >= labels.size()) {
    //old_name_ not found
    pos = -1;
}

return(pos);
}

void GenericEngine::BeginTimer()
{
    milliseconds ms = duration_cast< milliseconds >(
        system_clock::now().time_since_epoch()
    );
    start_time = ms;
}

inline long GenericEngine::EndTimer()
{
    milliseconds ms = duration_cast< milliseconds >(
        system_clock::now().time_since_epoch()
    );
    end_time = ms;
    return (end_time - start_time).count();
}

inline vector<string> GenericEngine::ToLabels(VectorXd y)
{
    vector<string> labels;
    for (long i = 0; i < y.size(); i++)
    {
        string s = LabelsVector[y(i)];
        labels.push_back(s);
    }
    return(labels);
}
```



```
inline TrainCrossSplits GenericEngine::LoadCSV(const string & inputfile, const bool bShuffle,
const bool bAddBias)
{
    int nr_rows = 0;
    int nr_cols = 0;
    string fname = inputfile;
    TrainCrossSplits rec_results;

    if (!file_exists(inputfile))
        throw std::invalid_argument("Received invalid file in LoadCSV: " + fname);

    ifstream infile(fname, std::ifstream::in);

    if (!infile.good())
        throw std::invalid_argument("Received invalid file in LoadCSV: " + fname);

    debug_info("Loading " + fname + " dataset...");
    vector< vector<string> > result;
    while (!infile.eof())
    {
        //go through every line
        string line;

        getline(infile, line);

        vector <string> record;
        nr_cols = 0;

        std::size_t prev = 0, pos;
        while ((pos = line.find_first_of(";", prev)) != std::string::npos)
        {
            if (pos > prev)
            {
                record.push_back(line.substr(prev, pos - prev));
                nr_cols++;
            }
        }
    }
}
```

```
        prev = pos + 1;
    }
    if (prev < line.length())
    {
        record.push_back(line.substr(prev, std::string::npos));
        nr_cols++;
    }

    if (nr_cols > 0)
    {
        result.push_back(record);
        nr_rows++;
    }
}

//
// now load whole data, X and y matrices
// assume last column of loaded data is the results / labels
//

LoadedDataNrFields = result[0].size();
LoadedDataNrRows = nr_rows - 1; // rows minus field names row

debug_info("Loaded " + std::to_string(LoadedDataNrRows) + " X " +
std::to_string(LoadedDataNrFields) + " dataset");

LoadedData = new MatrixXd(LoadedDataNrRows, LoadedDataNrFields);
y_loaded = new VectorXd(LoadedDataNrRows);
X_loaded = new MatrixXd(LoadedDataNrRows, LoadedDataNrFields - 1);

std::set <string> LabelsSet;

long i, j;
for (j = 0; j < LoadedDataNrFields; j++)
    LoadedDataHeader.push_back((string)result[0][j]);
```

```
//  
// assume dataset is curated and ONLY last column contains text labels  
//  
  
vector <string> loaded_labels;  
  
for (i = 0; i < LoadedDataNrRows; i++)  
    for (j = 0; j < LoadedDataNrFields; j++)  
    {  
        double fcell = 0;  
        string scell = result[i + 1][j];  
        try  
        {  
            if (j != (LoadedDataNrFields - 1))  
                fcell = ::atof(scell.c_str());  
        }  
        catch (...)  
        {  
        }  
        (*LoadedData)(i, j) = fcell;  
        if (j == (LoadedDataNrFields - 1))  
        {  
            LabelsSet.insert(scell);  
            loaded_labels.push_back(scell);  
        }  
    }  
  
LabelsVector.assign(LabelsSet.begin(), LabelsSet.end());  
  
for (int label_idx = 0; label_idx < loaded_labels.size(); label_idx++)  
{  
    string c_label = loaded_labels[label_idx];  
    int iLabel = FindLabelId(LabelsVector, c_label);  
    (*LoadedData)(label_idx, LoadedDataNrFields - 1) = iLabel;  
}
```

```
}

if (bShuffle)
{
    MatrixXd ttt = ShuffleMatrixRows(*LoadedData);
    *LoadedData = ttt;
}

float test_size = 0.2;
int test_rows = LoadedDataNrRows * test_size;
int train_rows = LoadedDataNrRows - test_rows;
TrainTestSplitPos = train_rows;

*X_loaded = LoadedData->leftCols(LoadedDataNrFields - 1);
*y_loaded = LoadedData->rightCols(1);

NR_FEATS = X_loaded->cols();
NR_CLASSES = LabelsVector.size();

if (bAddBias)
{
    // now add bias
    VectorXd bias(LoadedDataNrRows);
    bias.fill(1);
    MatrixXd *TempX = new MatrixXd(LoadedDataNrRows, LoadedDataNrFields - 1 + 1);
// bias size
    *TempX << bias, *X_loaded;
    bBiasAdded = true;
    delete X_loaded;
    X_loaded = TempX;
    // done adding bias
}

X_train = new MatrixXd(X_loaded->topRows(train_rows));
X_cross = new MatrixXd(X_loaded->bottomRows(test_rows));
```

```
y_train = new VectorXd(y_loaded->head(train_rows));
y_cross = new VectorXd(y_loaded->tail(test_rows));

rec_results.X_cross = *X_cross;
rec_results.X_train = *X_train;
rec_results.y_cross = *y_cross;
rec_results.y_train = *y_train;
rec_results.Labels = LabelsVector;

return(rec_results);

}

//
// END Generic Engine Class definitions
//

//
// BEGIN Generic Linear Engine (Virtual class)
//

inline float GenericLinearEngine::NRMSE(VectorXd y_hat, VectorXd y)
{
    float maxmin = y.maxCoeff()-y.minCoeff();
    return(RMSE(y_hat, y) / maxmin);
}

inline float GenericLinearEngine::RMSE(VectorXd y_hat, VectorXd y)
{
    long nr_obs = y.size();
    VectorXd errors = (y-y_hat);
    if (VERBOSE_ENGINE)
    {
        debug_info("Errors (last 3):");
        debug_info(errors.tail(3));
    }
    double sqNorm = errors.squaredNorm();
```

```
        return(sqrt(sqNorm / nr_obs));
    }

inline void GenericLinearEngine::add_cost(double J)
{
    if (nr_batches == 0)
    {
        // first use :)
        J_values = new VectorXd(1);
        (*J_values)(nr_batches) = J;
    }
    else
    {
        J_values->conservativeResize(nr_batches + 1);
        (*J_values)(nr_batches) = J;
    }
    nr_batches++;
}

inline void GenericLinearEngine::init()
{
    debug_info("Generating object [" + CLF_NAME + "]");

    nr_batches = 0;
    Theta = NULL;
    SingleClassTheta = NULL;
    J_values = NULL;
}

double myexp(double val)
{
    return(exp(val));
}

MatrixXd& GenericLinearEngine::GetTheta()
```



```
{
    return *Theta;
}

string GenericLinearEngine::GetName()
{
    return (CLF_NAME);
}

double myround(double f)
{
    return (round(f));
}

inline VectorXd GenericLinearEngine::PredictSingleClass(MatrixXd X)
{
    VectorXd *pred = new VectorXd(X.rows());

    *pred = X * (*SingleClassTheta);

    return(*pred);
}

inline MatrixXd GenericLinearEngine::Predict(MatrixXd X)
{
    MatrixXd preds = X * (*Theta);
    return(preds);
}

inline vector<string> GenericLinearEngine::PredictLabels(MatrixXd X)
{
    MatrixXd y_hat = Predict(X);
    vector<string> PredictedLabels;
```

```
for (long i = 0;i < y_hat.rows();i++)
{
    int y_hat_idx;
    y_hat.row(i).maxCoeff(&y_hat_idx);
    PredictedLabels.push_back(LabelsVector[y_hat_idx]);
}
return(PredictedLabels);
}

inline vector<string> GenericLinearEngine::PredictLabelsUsingYHat (MatrixXd y_hat)
{
    vector <string> PredictedLabels;
    for (long i = 0;i < y_hat.rows();i++)
    {
        int y_hat_idx;
        y_hat.row(i).maxCoeff(&y_hat_idx);
        PredictedLabels.push_back(LabelsVector[y_hat_idx]);
    }
    return(PredictedLabels);
}

inline float GenericLinearEngine::TrainEvaluationSingleClass(bool bClass)
{
    double dResult = 0.0f;
    VectorXd y = *y_train;
    MatrixXd X = *X_train;
    long nr_train = y.size();
    if (SingleClassTheta == NULL && Theta == NULL)
        return (dResult);

    VectorXd y_hat = PredictSingleClass(X);
    long nr_obs = y_hat.size();

    if (VERBOSE_ENGINE)
    {
        debug_info("Train Y_Hat vs. Y_train (last 3)");
        MatrixXd result(nr_train, 2);
    }
}
```



```
        result << y_hat, y;
        debug_info(result.bottomRows(3));
    }

    if (bClass)
    {
        VectorXd y_hat_Rounded = y_hat.unaryExpr(ptr_fun(myround));
        long positives = 0;
        for (long i = 0; i < nr_obs; i++)
        {
            if (y_hat_Rounded(i) == (y)(i))
                positives++;
        }
        dResult = (double)positives / nr_obs;
    }
    else
    {
        dResult = NRMSE(y_hat, y);
    }

    return (dResult);
}

inline float GenericLinearEngine::CrossEvaluation(bool bClass)
{
    double dResult = 0.0f;
    VectorXd y = *y_cross;
    MatrixXd X;
    if (!bBiasAdded)
        X = *X_cross;
    else
        X = X_cross->rightCols(NR_FEATS);

    long nr_cross = y.size();
    if (Theta == NULL)
        return (dResult);
}
```

```
MatrixXd y_hat = Predict(X);

long nr_obs = X.rows();

if (VERBOSE_ENGINE)
{
    MatrixXd result(nr_cross, y_hat.cols() + 1);
    result << y_hat, y;
    debug_info("Cross Y_Hat vs. Y_cross (last 5):",result.bottomRows(5));
}

if (bClass)
{
    vector <string> preds = PredictLabelsUsingYHat(y_hat);
    long positives = 0;
    for (long i = 0;i < nr_obs;i++)
    {
        string predicted = preds[i];
        string label = LabelsVector[(int)y(i)];
        if (predicted == label)
            positives++;
    }
    dResult = (double)positives / nr_obs;
}
else
{
    dResult = -1;
}

return (dResult);
}

inline float GenericLinearEngine::TrainEvaluation(bool bClass)
{
    double dResult = 0.0f;
    VectorXd y = *y_train;
```

```
MatrixXd X;

if (!bBiasAdded)
    X = *X_train;
else
    X = X_train->rightCols(NR_FEATS);

long nr_cross = y.size();
if (Theta == NULL)
    return (dResult);

MatrixXd y_hat = Predict(X);

long nr_obs = X.rows();

if (VERBOSE_ENGINE)
{
    MatrixXd result(nr_cross, y_hat.cols() + 1);
    result << y_hat, y;
    debug_info("Train Y_Hat vs. Y_train (last 5):", result.bottomRows(5));
}

if (bClass)
{
    vector <string> preds = PredictLabelsUsingYHat(y_hat);
    long positives = 0;
    for (long i = 0; i < nr_obs; i++)
    {
        string predicted = preds[i];
        string label = LabelsVector[(int)y(i)];
        if (predicted == label)
            positives++;
    }
    dResult = (double)positives / nr_obs;
}
else
{
    dResult = -1;
}
```

```
    }

    return (dResult);

}

inline float GenericLinearEngine::CrossEvaluationSingleClass(bool bClass)
{
    double dResult = 0.0f;
    VectorXd y = *y_cross;
    MatrixXd X = *X_cross;
    long nr_cross = y.size();
    if (SingleClassTheta == NULL && Theta == NULL)
        return (dResult);

    VectorXd y_hat = PredictSingleClass(X);
    long nr_obs = y_hat.size();

    if (VERBOSE_ENGINE)
    {
        debug_info("Cross Y_Hat vs. Y_cross (last 3)");
        MatrixXd result(nr_cross, 2);
        result << y_hat, y;
        debug_info(result.bottomRows(3));
    }

    if (bClass)
    {
        VectorXd y_hat_Rounded = y_hat.unaryExpr(ptr_fun(myround));
        long positives = 0;
        for (long i = 0; i < nr_obs; i++)
        {
            if (y_hat_Rounded(i) == y(i))
                positives++;
        }
        dResult = (double) positives / nr_obs;
    }
}
```

```
else
{
    dResult = NRMSE(y_hat, y);
}

return (dResult);
}
//
// END Generic Linear Engine virtual class
//

//
// BEGIN Normal Regressor class definitions
//

void NormalRegressor::Train(MatrixXd X, MatrixXd y)
{
    X_train = new MatrixXd(X);
    y_train = new VectorXd(y);
    Train();
}

template<typename _Matrix_Type_>
_Matrix_Type_ pseudoInverse(const _Matrix_Type_ &a, double epsilon =
std::numeric_limits<double>::epsilon())
{
    Eigen::JacobiSVD< _Matrix_Type_ > svd(a, Eigen::ComputeThinU | Eigen::ComputeThinV);
    double tolerance = epsilon * std::max(a.cols(), a.rows())
*svd.singularValues().array().abs()(0);
    return svd.matrixV() * (svd.singularValues().array().abs() >
tolerance).select(svd.singularValues().array().inverse(), 0).matrix().asDiagonal() *
svd.matrixU().adjoint();
}

void NormalRegressor::Train()
{
    debug_info("Training: " + CLF_NAME);
    MatrixXd X = *X_train;
```

```
VectorXd y = *y_train;
MatrixXd xTx = X.transpose() * X;
MatrixXd xT = X.transpose();

VectorXd TempTheta1(X.cols());
VectorXd TempTheta2(X.cols());

long duration1;
long duration2;

if (VERBOSE_ENGINE)
{
    // 1st solving with pseudo-inverse
    high_resolution_clock::time_point t1 = high_resolution_clock::now();
    MatrixXd xTxInv = pseudoInverse(xTx);
    TempTheta1 = xTxInv * xT * y;
    high_resolution_clock::time_point t2 = high_resolution_clock::now();
    duration1 = duration_cast<microseconds>(t2 - t1).count();

    // now second method
    high_resolution_clock::time_point t3 = high_resolution_clock::now();
    TempTheta2 = xTx.ldlt().solve(xT * y);
    high_resolution_clock::time_point t4 = high_resolution_clock::now();
    duration2 = duration_cast<microseconds>(t4 - t3).count();

    //SingleClassTheta = new VectorXd(TempTheta1);
    SingleClassTheta = new VectorXd(TempTheta2);

}
else
{
    // now second method
    TempTheta2 = xTx.ldlt().solve(xT * y);
    SingleClassTheta = new VectorXd(TempTheta2);
}
```

```
if (VERBOSE_ENGINE)
{
    debug_info("X data features size = " + to_string(X_loaded->cols()));

    debug_info("Theta PInv = " + to_string(duration1) + " microsec");
    debug_info("Theta ldlt = " + to_string(duration2) + " microsec");

    debug_info("T1(pinv) T2(ldlt):");
    MatrixXd comp(TempTheta1.size(), 2);
    comp << TempTheta1, TempTheta2;
    debug_info(comp);
    if (*SingleClassTheta == TempTheta2)
        debug_info("Using Theta2");
    else
        debug_info("Using Theta1");
}
}
//
// END Normal Regressor class definitions
//

inline void OnlineClassifier::SimulateOnlineTrain()
{
    if (Theta != NULL)
        delete Theta;

    Theta = new MatrixXd(NR_FEATS + 1, NR_CLASSES);
    Theta->fill(0); // reset Theta

    long TEST_DEBUG = 1000;

    BeginTimer();

    for (long i = 0; i < X_train->rows(); i++)
    {
```

```
MatrixXd obs = X_train->row(i);
VectorXd yi(1);
yi(0) = (*y_train)(i);

if (VERBOSE_ENGINE)// && (i == TEST_DEBUG)
{
    std::stringstream ss;
    for (size_t i = 0; i < yi.size(); ++i)
    {
        if (i != 0)
            ss << ",";
        ss << yi[i];
    }

    debug_info("Training " + to_string(i) + " th example with y = " +
ss.str(), obs);
}

MatrixXd xi;
if (bBiasAdded)
    xi = obs.rightCols(NR_FEATS);
else
    xi = obs;

OnlineTrain(xi, yi);

if (VERBOSE_ENGINE)// && (i == TEST_DEBUG)
{
    //long time_cost = EndTimer();
    //debug_info("Total time = " + to_string(time_cost) + " ms");
    debug_info("y_OHM (1 row): ", LastYOHM.topRows(1));
    debug_info("y_hat (1 row): ", LastYHat.topRows(1));
    debug_info("error (1 row): ", LastYERR.topRows(1));
    debug_info("Gradient (2 rows): ", LastGrad.topRows(2));

    debug_info("J array las val: ", J_values->tail(1), true);
    debug_info("Theta (2 rows): ", Theta->topRows(2));
}
```



```
//debug_info();

    }

}

}

//
// BEGIN Online Classifier definitions
//
// yi is index in VectorLabels
void OnlineClassifier::OnlineTrain(MatrixXd xi, VectorXd yi)
{
    long nr_rows = xi.rows();
    long nr_cols = xi.cols();

    VectorXd bias(nr_rows);
    bias.fill(1);
    MatrixXd TempX(nr_rows, nr_cols + 1);
    TempX << bias, xi;

    long m = nr_rows; // for convenience
    MatrixXd yOHM(nr_rows, NR_CLASSES);
    yOHM.fill(0);
    for (long i = 0; i < nr_rows; i++)
    {
        for (long j = 0; j < NR_CLASSES; j++)
            // now assume LabelsVector is correctly constructed
            // and yi[i] is index in that vector
            if (yi(i) == j)
                yOHM(i, j) = 1;
    }

    // now we have the one hot matrix lets start working !
    MatrixXd y_hat = Predict(xi);
    double J = (1.0 / m) * cross_entropy(yOHM, y_hat); // MUST add regularization
    add_cost(J);

    MatrixXd error = yOHM - y_hat;
```

```
MatrixXd Grad = (-1.0 / m) * TempX.transpose() * error; // MUST add regularization

*Theta = *Theta - (LearningRate * Grad);

LastGrad = Grad;
LastYOHM = yOHM;
LastYHat = y_hat;
LastYERR = error;
LastXObs = xi;

}

inline double OnlineClassifier::CostFunction()
{

    return 0.0;

}

inline MatrixXd OnlineClassifier::Predict(MatrixXd X)
{

    long nr_rows = X.rows();
    long nr_cols = X.cols();

    VectorXd bias(nr_rows);
    bias.fill(1);
    MatrixXd TempX(nr_rows, nr_cols + 1);
    TempX << bias, X;
    MatrixXd XTheta = TempX * (*Theta);

    MatrixXd SM = softmax(XTheta);

    return (SM);

}

inline MatrixXd OnlineClassifier::softmax(MatrixXd z)
{


```

```
MatrixXd SM(z.rows(), Theta->cols());

ArrayXXd arr(z);

// first shift values
arr = arr - z.maxCoeff();
arr = arr.exp();

//cout << z;
//cout << arr;

ArrayXd sums = arr.rowwise().sum();

arr.colwise() /= sums;

SM = arr.matrix();

return(SM);
}

double myclip(double val)
{
    double eps = 1e-15;
    if (val < eps)
        return(eps);
    else
        if (val > (1 - eps))
            return(1 - eps);
        else
            return(val);
}

inline double OnlineClassifier::cross_entropy(MatrixXd yOHM, MatrixXd y_hat)
{
    //y_hat = y_hat.unaryExpr(ptr_fun(myclip));

    MatrixXd J_matrix = (yOHM.array() * y_hat.array().log()).matrix();
}
```

```
double J = -(J_matrix.sum());  
return(J);  
}  
//  
// END Online Classifier definitions  
//
```

4.2 Tehnici bazate pe Retele Neurale Adanci

4.2.1 Utilizarea CNN in segmentarea semantica

Retelele convolutionale adanci constituie principalul vector stiintific si tehnologic care avanseaza stadiul actual al tehnologiei si cercetarii in domeniul recunoasterii computerizate.

Rețelele convolutionale sunt modele de Machine Learning cu capabilitati de vizualizare puternice, care produce ierarhii de caracteristici. Intrinsec, rețelele convolutionale adanci ne pot prezenta informatia vizualala pe diverse nivele de analiza semantica cu ajutorul nivelelor “ascunse” (hidden layers) de neuroni artificiali. Conform lucrarii stiintifice “**Fully Convolutional Networks for Semantic Segmentation**” publicata de Johnatan Long, Trevor Darell et al. se arata ca rețelele convolutionale dense si complete se pot proiecta si construi astfel incat sa genereze predictii si inferente semantice complete la nivel de pixel – acesta fiind pasul natural al modificarii predictiei brute de la nivelul intregii imagini care este analiza pana la nivelul punctului grafic unitar (pixel). Astfel se poate asocia fiecare pixel individual cu o anumita forma bidimensionala sau tridimensionala.

4.2.2 Utilizarea LSTM pentru sisteme expert de tip Bot

Retelele neurale de tip LSTM (Long Short Term Memory) simuleaza functionarea neuronilor biologici responsabili de stocarea informatiei pe termen scurt si lung cu ajutorul unei porti de scriere, stocare si rescriere.

In materialele studiate este demonstrat atat prin formalizare matematica la nivel de model abstract de Machine Learning cat si prin demonstratii experimentale ca rețelele neurale adanci de tip LSTM pot fi antranate complet cu script-uri de tip call-center sau alte tipuri de conversatii realizate anterior intre actori umani. In urma antrenarii rețeaua LSTM este capabila sa formuleze raspunsuri coerente si logice la intrebari/probleme descrise de un utilizator uman in

limbaj natural – utilizand fraza/intrebarea in limbaj natural a operatorului uman ca si punct de plecare a analizei si predictiei raspunsului ideal.

Concret vom utiliza retele de tip LSTM in vederea realizarii unui Bot care sa permita unui utilizator uman sa descrie modul de functionare al aplicatiei informatice dorite iar sistemul Cloudifier.NET va putea formaliza in limbaje de programare notiunile intelese, analizate si proiectate de componentele LSTM ale Bot-ului.

4.2.3 Framework-ul state-of-the-art TensorFlow

Pentru implementarea tuturor algoritmilor de tip Deep Learning se va utiliza state-of-the-art actual in acest domeniu lansat de Google in anul 2016 – framework-ul TensorFlow impreuna cu framework-ul Keras care are scopul de a adauga facilitati de nivel inalt bibliotecilor TensorFlow. In continuare este prezentata sintaxa TensorFlow (descrisa in limbajul Python) urmata de sintaxa Keras.

```
import tensorflow as tf
import numpy as np

# Create 100 phony x, y data points in NumPy, y = x * 0.1 + 0.3
x_data = np.random.rand(100).astype(np.float32)
y_data = x_data * 0.1 + 0.3

# Try to find values for W and b that compute y_data = W * x_data + b
# (We know that W should be 0.1 and b 0.3, but TensorFlow will
# figure that out for us.)
W = tf.Variable(tf.random_uniform([1], -1.0, 1.0))
b = tf.Variable(tf.zeros([1]))
y = W * x_data + b

# Minimize the mean squared errors.
loss = tf.reduce_mean(tf.square(y - y_data))
optimizer = tf.train.GradientDescentOptimizer(0.5)
train = optimizer.minimize(loss)
```

```
# Before starting, initialize the variables. We will 'run' this first.
init = tf.global_variables_initializer()

# Launch the graph.
sess = tf.Session()
sess.run(init)

# Fit the line.
for step in range(201):
    sess.run(train)
    if step % 20 == 0:
        print(step, sess.run(W), sess.run(b))

# Learns best fit is W: [0.1], b: [0.3]
```

4.2.4 Framework-ul state-of-the-art Keras

```
from keras.models import Sequential
from keras.layers import Dense, Dropout, Activation
from keras.optimizers import SGD

model = Sequential()
# Dense(64) is a fully-connected layer with 64 hidden units.
# in the first layer, you must specify the expected input data shape:
# here, 20-dimensional vectors.
model.add(Dense(64, input_dim=20, init='uniform'))
model.add(Activation('tanh'))
model.add(Dropout(0.5))
model.add(Dense(64, init='uniform'))
model.add(Activation('tanh'))
model.add(Dropout(0.5))
model.add(Dense(10, init='uniform'))
model.add(Activation('softmax'))

sgd = SGD(lr=0.1, decay=1e-6, momentum=0.9, nesterov=True)
model.compile(loss='categorical_crossentropy',
              optimizer=sgd,
              metrics=['accuracy'])

model.fit(X_train, y_train,
        nb_epoch=20,
        batch_size=16)
score = model.evaluate(X_test, y_test, batch_size=16)
```

5 Anexa – Rapoarte lunare

5.1 Raport stiintific lunar 1

Raport stiintific

de cercetare-dezvoltare in cadrul Cloudifier SRL

Nr. 62/31.10.2016

Nume proiect	Platforma de migrare automatizată în cloud a aplicațiilor și sistemelor informatice clasice cloudifier.net
Beneficiar	CLOUDIFIER SRL
Cod MySMIS	104349
Nr. inregistrare	P_38_543
Director Proiect	Andrei Ionut DAMIAN
Activitate conform planului de proiect	1. Activități de cercetare-dezvoltare (cercetare industrială și/sau dezvoltare experimentală) - 1.1 State-of-the-art
Luna	Octombrie 2016
Echipa de cercetare-dezvoltare	Andrei Ionut DAMIAN Octavian BULIE
Descrierea activitatilor desfasurate activitatii	In decursul acestei luni a inceput procesul de analiza a stadiului curent al tehnologiei in domeniul sistemelor de tip Machine Learning cu accent pe zona de Deep Learning, domeniu de

cercetare in dezvoltare la nivel international ce a luat amploare deosebita in ultimii 5 ani.

Scopul analizei stadiului actual al tehnologiei este acela de a determina metodele cele mai moderne/actuale de realizare a predictiilor/inferentelor in imagistica – in particular in cazul proiectului CLOUDIFIER referindu-ne la analiza imaginilor captate in timp real in timpul functionarii aplicatiilor si implicit analiza automatizata cu ajutorul recunoasterii avansate de forme/imagini a aplicatiilor “legacy” in vederea translatarii acestora automatizate.

In decursul lunii octombrie 2016 au fost analizate cele mai recente si avansate lucrari de cercetare fundamentala si industriala provenite de la cele mai prestigioase institute si universitati printre care enumeram:

- Caltech – California Institute for Technology
- MIT – Massachusetts Institute for Technology
- Stanford
- University of Toronto
- Harvard
- University of Washington

Principalele zone analizate au fost:

- Metodele de tip Deep Learning bazate pe Retele Neuronale Convolutionale – Deep Convolutional Neural Networks
- Metode de tip shallow learning pentru invatarea supervizata a structurilor si a elementelor de imagistica utilizand modele de invatare in timp real (online learning)

- Cele mai moderne abordari in Deep Learning – Tensor Flow
- Cele mai moderne abordari in shallow learning – Extreme Boosted Decision Trees / Random Forests - XGBoost

In decursul lunilor noiembrie si decembrie se va continua analiza conform graficului de implementare a proiectului cu accent pe urmatoarele:

- Determinarea unui algoritm ideal pentru identificarea primitivelor de interfata grafica (butoane, campuri, ferestre, texte statice, etc) si a pozitiei acestora in cadrul ecranelor interfetelor grafice
- Determinarea unui algoritm de tip Machine Learning pentru generarea AUTOMATA de interfe grafice si cod sursa aferente pe baza schitelor facute manual pe suport de hartie, tabla, etc
- Analiza TensorFlow
- Analiza XGBoost
- Analiza metode si propuneri pentru biblioteci interne
- Analiza si testarea experimentală a mediilor de procesare numerica masiv paralela cu ajutorul GPU (tehnologiile bazate pe nuclee de calul masiv paralel CUDA)

Perioada	Efort in ore-om	Descriere
3.10.2016-14.10.2016	160	Selectia si analiza preliminara a celor mai importante lucrari din domeniul recunoasterii de imagini cu ajutorul retelelor adanci neurale convolutionale (Deep Convolutional Neural Networks). A fost inceputa analiza state-of-the-art pe ultimile

17.10.2016- 21.10.2016	80	<p>cercetari realizate de laboratoarele de cercetare ale Google in Inteligenta Artificiala – biblioteca TensorFlow</p> <p>Analiza XGBoost – actualmente cea mai puternica infrastruktura si biblioteca de shallow learning bazata pe modele de tip ansamblu</p> <p>Inceperea efectuarii de teste experimentale pe modele arhitecturale simple bazate pe regresii logistice adaptate si optimizate online si retele neural cu conectare completa. Testele s-au realizat dupa cum urmeaza:</p> <ul style="list-style-type: none">• Python cu ajutorul:<ul style="list-style-type: none">○ Sci-Kit-Learn○ Biblioteca dezvoltata intern in cadrul Cloudifier pentru regresii logistice avansate (OnlineClassifierEngine.py)○ Biblioteca de retele neurale cu conectivitate completa realizata in cadrul Cloudifier• C++ cu ajutorul bibliotecii de calcul numeric optimizat Eigen
24.10.2016- 31.10.2016	96	

5.2 Raport stiintific lunar 2

Raport stiintific

de cercetare-dezvoltare in cadrul Cloudifier SRL

Nr. 98/29.12.2016

Nume proiect	Platforma de migrare automatizată în cloud a aplicațiilor și sistemelor informatice clasice cloudifier.net
Beneficiar	CLOUDIFIER SRL
Cod MySMIS	104349
Nr. inregistrare	P_38_543
Director Proiect	Andrei Ionut DAMIAN
Activitate conform planului de proiect	1. Activități de cercetare-dezvoltare (cercetare industrială și/sau dezvoltare experimentală) - 1.1 State-of-the-art
Luna	Noiembrie 2016
Echipa de cercetare-dezvoltare	Andrei Ionut DAMIAN Octavian BULIE
Descrierea activitatilor desfasurate activitatii	In decursul acestei luni a fost continuat procesul de analiza a stadiului curent al tehnologiei in domeniul sistemelor de tip Machine Learning cu accent pe zona de Deep Learning, domeniu de cercetare in dezvoltare la nivel international ce a luat amploare deosebita in ultimii 5 ani. Scopul analizei stadiului actual al tehnologiei este acela de a determina metodele cele mai moderne/actuale de realizare a

predictiilor/inferentelor in imagistica – in particular in cazul proiectului CLOUDIFIER referindu-ne la analiza imaginilor captate in timp real in timpul functionarii aplicatiilor si implicit analiza automatizata cu ajutorul recunoasterii avansate de forme/imagini a aplicatiilor “legacy” in vederea translatarii acestora automatizate.

In decursul lunii noiembrie 2016 au fost analizate cele mai recente si avansate lucrari de cercetare fundamentala in vederea determinarii unui set de algoritmi de Machine Learning ideali pentru identificarea primitivelor de interfata grafica (butoane, campuri, ferestre, texte statice, etc) si a pozitiei acestora in cadrul ecranelor interfetelor grafice

- Determinarea unui algoritm de tip Machine Learning pentru generarea AUTOMATA de interfe grafice si cod sursa aferente pe baza schitelor facute manual pe suport de hartie, tabla, etc
- Analiza TensorFlow
- Analiza XGBoost
- Analiza metode si propuneri pentru biblioteci interne
- Analiza si testarea experimentală a mediilor de procesare numerica masiv paralela cu ajutorul GPU (tehnologiile bazate pe nuclee de calul masiv paralel CUDA)

In decursul lunii decembrie se va continua analiza inceputa in lunile octombrie si noiembrie conform graficului de implementare a proiectului.

Perioada	Efort in ore-om	Descriere
01.11.2016- 11.11.2016	144	Analiza model arhitectural de Retea Neurala total conectata in Python pentru analiza elementelor de interfata grafica si testarea experimentală a acesteia pe seturi de data de imagistica. Analiza PyCUDA – infrastructura programabila pentru procesoarele de calcul numeric masiv paralel CUDA
14.11.2016- 30.11.2016	208	Testarea in regim CPU si GPU a celui mai recent framework de Deep Learning realizat de laboaratoarele de cercetare ale Google – TensorFlow

5.3 Raport stiintific lunar 3

Raport stiintific lunar

de cercetare-dezvoltare în cadrul Cloudifier SRL

Nr. 112/9.12.2016

Nume proiect	Platforma de migrare automatizată în cloud a aplicațiilor și sistemelor informatice clasice cloudifier.net
Beneficiar	CLOUDIFIER SRL
Cod MySMIS	104349
Nr. inregistrare	P_38_543
Director Proiect	Andrei Ionut DAMIAN
Activitate conform planului de proiect	1. Activități de cercetare-dezvoltare (cercetare industrială și/sau dezvoltare experimentală) - 1.1 State-of-the-art
Luna	decembrie 2016
Echipa de cercetare-dezvoltare	Andrei Ionut DAMIAN Octavian BULIE
Descrierea activitatilor desfasurate activitatii	In decursul acestei luni a fost continuat procesul de analiza a stadiului curent al tehnologiei in domeniul sistemelor de tip Machine Learning cu accent pe zona de Deep Learning si in particular a sistemelor de analiza si recunoastere bazata pe inteligenta artificiala a imaginilor.

In decursul acestei luni analiza stadiului curent al cercetării fost fost axat în principal pe lucrarea științifică publicată recent de J. Long et al “Fully Convolutional Networks for Semantic Segmentation”, lucrare considerată actualmente state-of-the-art în ceea ce privește metodele de recunoaștere și segmentare a componentelor în cadrul imaginilor. Pentru referință prezentăm anexat un scurt rezumat în limba engleză a lucrării de referință.

Principalele puncte pe care le urmărim în cercetare sunt următoarele:

1. Determinarea metodelor optime bazate pe Deep Learning pentru recunoașterea și segmentarea (identificarea locației spațiale) a elementelor de interfață grafică pe care Cloudifier.NET va trebuie să le translateze automatizat din aplicațiile legacy în aplicațiile din mediul cloud computing.
2. Aplicarea de metode simple bazate pe algoritmi de machine learning superficiali (regresie logistică, arbori de decizie, clasificare naivă bazată pe teorema lui Bayes, clusterizare cu analiză a distanțelor euclidiene) precum și metode de segmentare iterativă a imaginilor analizate cum ar fi metoda ferestrelor deplasate continuu (“ferestre alunecătoare” sau sliding-windows algorithm)

Perioada	Efort în ore-om	Descriere
01.12.2016-09.12.2016	96	Continuarea analizei metodelor de recunoaștere a imaginilor prin CNN (Convolutional Deep Neural Networks)
12.12.2016-	224	

Perioada	Efort in ore-om	Descriere
31.12.2016		<p>Analiza unui model arhitectural Alpha ce urmeaza a fi definitivat in cadrul activitatii 1.2 de cercetare.</p> <p>Sistemul/model arhitectural Alpha va consta in construirea unui model matematic predictiv care sa poate recunoaste elemente simple de interfata grafica de utilizator (meniu, buton, etc) si sa poata reda locatia si 1-2 alte attribute de baza ale acestora</p>

Fully Convolutional Networks for Semantic Segmentation

Evan Shelhamer, Jonathan Long, Trevor Darrell

(Submitted on 20 May 2016)

Convolutional networks are powerful visual models that yield hierarchies of features. We show that convolutional networks by themselves, trained end-to-end, pixels-to-pixels, improve on the previous best result in semantic segmentation. Our key insight is to build "fully convolutional" networks that take input of arbitrary size and produce correspondingly-sized output with efficient inference and learning. We define and detail the space of fully convolutional networks, explain their application to spatially dense prediction tasks, and draw connections to prior models. We adapt contemporary classification networks (AlexNet, the VGG net, and GoogLeNet) into fully convolutional networks and transfer their learned representations by fine-tuning to the segmentation task. We then define a skip architecture that combines semantic information from a deep, coarse layer with appearance information from a shallow, fine layer to produce accurate and detailed segmentations. Our fully convolutional network achieves improved segmentation of PASCAL VOC (30% relative improvement to 67.2% mean IU on 2012), NYUDv2, SIFT Flow, and PASCAL-Context, while inference takes one tenth of a second for a typical image.

Comments: to appear in PAMI (accepted May, 2016); journal edition of arXiv:1411.4038

Subjects: Computer Vision and Pattern Recognition (cs.CV)

Cite as: arXiv:1605.06211 [cs.CV]